

Statistika

- pitanja za usmeni -

1. Što je slučajni eksperiment?

Slučajni eksperiment je radnja ili pojava koja rezultira nepoznatim ishodima.

2. Što je prostor elementarnih događaja?

Prostor elementarnih događaja je skup svih mogućih ishoda slučajnog eksperimenta (Ω).

3. Što je slučajni događaj?

Slučajni događaj je podskup prostora elementarnih događaja (Ω).

4. Kako glasi naivna definicija vjerojatnosti?

Vjerojatnost nekog slučajnog događaja je broj slučajnih eksperimenata u kojima se dogodio taj slučajni događaj, podijeljen sa ukupnim brojem mogućih ishoda slučajnog eksperimenta, pod pretpostavkom da su svi elementarni događaji jednako vjerojatni.

5. Što je sigma-algebra?

Sigma-algebra je familija podskupova skupa Ω koja sadrži prazan skup, takva da ako je neki skup u sigma-algebri, tada je i njegov komplement u sigma-algebri, i da je svaka prebrojiva unija članova sigma-algre ujedno član sigma-algre.

6. Što je vjerojatnost?

Vjerojatnost je funkcija iz sigma-algre $\mathcal{F}$ u skup realnih brojeva $\mathbb{R}$ koja slučajnim događajima pridružuje vrijednosti između 0 i 1, takva da je vjerojatnost svakog elementa (slučajnog događaja) sigma-algre veća ili jednaka nuli, da je vjerojatnost cijelog prostora Ω jednaka jedan te da je vjerojatnost unije bilo kojeg prebrojivog niza međusobno disjunktih elemenata sigma-algre jednaka zbroju njihovih vjerojatnosti (prebrojiva odnosno sigma-aditivnost).

7. Što je vjerojatnosni prostor?

Vjerojatnosni prostor je uređena trojka $(\Omega, \mathcal{F}, P)$ u kojoj je Ω skup svih mogućih ishoda, $\mathcal{F}$ skup slučajnih događaja, a P funkcija koja svakom slučajnom događaju pridružuje njegovu vjerojatnost.

8. Što je uniformna vjerojatnost?

Uniformnom vjerojatnošću nazivamo kad svi elementi iz Ω imaju istu vjerojatnost koju definiramo kao $1/n$, gdje je n broj članova skupa Ω .

9. Što je nezavisnost?

Slučajni događaji su nezavisni ako za svaki konačni izbor među tim događajima vrijedi da je vjerojatnost njihovog presjeka jednaka produktu vjerojatnosti pojedinih događaja.

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$$

10. Što je uvjetna vjerojatnost?

Uvjetna vjerojatnost je vjerojatnost jednog slučajnog događaja s obzirom na drugi i jednaka je vjerojatnosti presjeka ta dva slučajna događaja podijeljenoj s vjerojatnošću drugog događaja.

$$P(A | C) = \frac{P(A \cap C)}{P(C)}$$

11. Što opisuje formula potpune vjerojatnosti?

Formula potpune vjerojatnosti je način izračuna vjerojatnosti nekog slučajnog događaja kao zbroja uvjetnih vjerojatnosti tog događaja po svim događajima koji čine potpun i međusobno disjunktan sustav, pri čemu se svaka uvjetna vjerojatnost množi s vjerojatnošću pripadnog događaja.

$$P(A) = P(H_1)P(A | H_1) + \dots + P(H_n)P(A | H_n) = \sum_{i=1}^n P(H_i) P(A | H_i)$$

12. Što je slučajna varijabla?

Slučajna varijabla je funkcija definirana nad prostorom elementarnih događaja Ω koja elementima skupa Ω pridružuje vrijednost iz skupa realnih brojeva ($\mathbb{R}$), ili intuitivno možemo reći da je slučajna varijabla funkcija koja nam daje odgovor na neko pitanje vezano uz prostor elementarnih događaja u obliku kvantitativnog podatka (npr. koliko je glava palo pri bacanju novčića, zbroj brojeva na kockicama).

$$X : \Omega \rightarrow \mathbb{R}$$

13. Koja je razlika između diskretnih i neprekidnih slučajnih varijabli?

Diskretne slučajne varijable imaju prebrojiv skup vrijednosti i opisuju se funkcijom vjerojatnosti (razdiobom), dok neprekidne imaju neprebrojiv skup vrijednosti i opisuju se funkcijom gustoće.

$$X \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_n & \cdots \\ p_1 & p_2 & \cdots & p_n & \cdots \end{pmatrix} \rightarrow (diskretne)$$

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \quad x \in \mathbb{R} \rightarrow (neprekidne)$$

14. Što je funkcija distribucije?

Funkcija distribucije je funkcija koja svakom realnom broju pridružuje vjerojatnost da je vrijednost slučajne varijable manja ili jednaka tom broju.

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

15. Koje su poznatije diskretne razdiobe?

- Diskretna uniformna razdioba - svaka vrijednost slučajne varijable ima jednaku vjerojatnost

$$X \sim \begin{pmatrix} 1 & 2 & \cdots & n \\ \frac{1}{n} & \frac{1}{n} & \cdots & \frac{1}{n} \end{pmatrix}$$

- Bernoullijeva razdioba - slučajna varijabla ima samo dva ishoda, uspjeh i neuspjeh

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$$

- Binomna razdioba - slučajna varijabla broji koliko se puta dogodio uspjeh u n nezavisnih ponavljanja istog pokusa

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

- Geometrijska razdioba - slučajna varijabla broji koliko je ponavljanja potrebno do prvog uspjeha u nizu nezavisnih pokusa

$$P(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots$$

16. Kada su slučajne varijable nezavisne?

Slučajne varijable $X_1, X_2, \dots, X_n$ su nezavisne ako za sve skupove $A_1, A_2, \dots, A_n$ podskupove realnih brojeva vrijedi da je vjerojatnost da X_1 pripada A_1, X_2 pripada A_2 , i tako dalje do X_n pripada A_n jednaka produktu njihovih pojedinačnih vjerojatnosti.

$$P\left(\bigcap_{i=1}^n \{X_i \in B_i\}\right) = \prod_{i=1}^n P(X_i \in B_i)$$

17. Što je funkcija gustoće?

Funkcija gustoće je funkcija koja vrijednostima slučajne varijable pridružuje relativnu vjerojatnost, odnosno pokazuje gdje su vrijednosti varijable češće, a gdje rjeđe.

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \quad x \in \mathbb{R}$$

18. Koje su poznatije neprekidne razdiobe?

- Normalna razdioba - neprekidna razdioba određena parametrima očekivanja i varijance, čija je gustoća zvonastog oblika

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$$

- Eksponencijalna razdioba - neprekidna razdioba s parametrom lambda koja se često koristi za modeliranje vremena čekanja do događaja, a veći lambda rezultira strmijim grafom

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0 \end{cases}$$

- Uniformna razdioba - neprekidna razdioba na intervalu od a do b u kojoj su sve vrijednosti unutar intervala jednako vjerojatne pa je gustoća konstantna

$$f_U(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b), \\ 0, & \text{inače} \end{cases}$$

19. Kako se računaju očekivanje i varijanca za diskretne slučajne varijable?

- očekivanje - prosječna vrijednost dobivena množenjem svake vrijednosti slučajne varijable s njenom vjerojatnošću te sumiranjem svih umnožaka

$$\mathbb{E}[X] = \sum_{i=1}^n a_i p_i = \sum_{i=1}^n a_i P(X = a_i)$$

- varijanca - mjera raspršenosti dobivena tako da se svaka vrijednost slučajne varijable umanjuje za vrijednost očekivanja, svaki rezultat se potom kvadrira i množi sa vjerojatnošću te vrijednosti, a na kraju se svi dobiveni umnošci zbroje

$$\text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}X)^2.$$

20. Kako se računa očekivanje i varijanca za neprekidne slučajne varijable?

- očekivanje - prosječna vrijednost dobivena integriranjem vrijednosti slučajne varijable pomnožene njezinom gustoćom vjerojatnosti preko cijelog raspona mogućih vrijednosti

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

- varijanca - mjera raspršenosti dobivena tako da se vrijednost slučajne varijable umanjuje za vrijednost očekivanja, rezultat se potom kvadrira, množi s njezinom gustoćom vjerojatnosti i integrira preko cijelog raspona mogućih vrijednosti

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mathbb{E}X)^2 f_X(x) dx.$$

21. Što je kovarijanca?

Kovarijanca je mjera međuovisnosti dvije slučajnih varijabli koja se dobiva tako da se od očekivanja umnoška slučajnih varijabli oduzme umnožak njihovih očekivanja.

$$\text{Cov}(X, Y) = E(XY) - EX EY$$

22. Što je korelacija?

Korelacija je standardizirana kovarijanca tj. kovarijanca podijeljena s umnoškom standardnih devijacija (korijena varijance) dviju slučajnih varijabli.

$$\rho(X, Y) = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

23. Objasni Markovljevu nejednakost?

Markovljeva nejednakost kaže da za nenegativnu slučajnu varijablu vjerojatnost da poprimi vrijednosti veće od zadane ne može biti veća od omjera njezina očekivanja i te vrijednosti.

24. Objasni Čebiševljevu nejednakost?

Čebiševljeva nejednakost daje gornju granicu vjerojatnosti da slučajna varijabla odstupa od svojeg matematičkog očekivanja za više od određenog broja standardnih devijacija

25. Što govori zakon velikih brojeva?

- Zakon velikih brojev govori o konvergenciji prosjeka slučajnih varijabli.
- Slabi zakon velikih brojeva - što veći broj nezavisnih i jednako distribuiranih slučajnih varijabli uzmemo, to je vjerojatnije da će se njihov prosjek jako malo razlikovati od očekivanja pojedinačne slučajne varijable, odnosno da su prosjeci sve koncentriraniji oko samog očekivanja
- Jaki zakon velikih brojeva - što veći broj nezavisnih i jednako distribuiranih slučajnih varijabli uzmemo, njihov prosjek gotovo sigurno ($P = 1$) konvergira prema očekivanju pojedinačne slučajne varijable

26. Što govori centralni granični teorem?

Govori o obliku distribucije prosjeka slučajnih varijabli odnosno, što veći broj nezavisnih i jednako distribuiranih slučajnih varijabli s konačnim očekivanjem i varijancom uzmemo, njihov prosjek umanjuje se za očekivanje i podijeljen standardnom devijacijom prosjeka konvergira u distribuciji prema normalnoj distribuciji.

27. Što je uzorak?

Uzorak je niz nezavisnih i jednako distribuiranih slučajnih varijabli.

28. Što je slučajni uzorak?

Slučajni uzorak je uzorak gdje svaki element populacije ima jednaku vjerojatnost da bude izabran.

29. Koje vrste statističkih modela postoje?

Parametarski i neparametarski.

30. Što je statistika i navedi primjere?

Statistika je funkcija slučajnog uzorka.

Primjeri:

- Uzoračka sredina - aritmetička sredina (prosjeak) slučajnih varijabli koje čine uzorak

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- Uzoračka varijanca - prosjek kvadrata odstupanja uzoračkih vrijednosti od uzoračke sredine

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

31. Što su momenti?

Moment je očekivanje slučajne varijable na neku potenciju ($E[X]$ - prvi moment, $E[X^2]$ - drugi moment, $E[X^3]$ - treći moment...).

32. Što je procjenitelj?

Procjenitelj je statistika (slučajna varijabla) kojom procjenjujemo željeni nepoznati parametar populacije.

33. Što je procjena?

Procjena je rezultat (broj) koji predstavlja aproksimaciju traženog parametra populacije.

34. Što je statistička hipoteza?

Statistička hipoteza je tvrdnja o nekom parametru populacije.

35. Što je testiranje statističkih hipoteza?

Testiranje statističkih hipoteza je postupak kojim donosimo odluku o nekoj tvrdnji o populaciji na temelju slučajnog uzorka.

	H_0 istinita	H_1 istinita
H_0 odbačena	Greška I vrste	Ispravna odluka
H_0 prihvaćena	Ispravna odluka	Greška II vrste

36. Što je nul hipoteza?

Nul hipoteza je statistička hipoteza koju smatramo točnom dok se ne pokaže suprotno.

37. Što je alternativna hipoteza?

Alternativna hipoteza je ono što želimo dokazati podacima a suprotstavlja se nul hipotezi.

38. Što je testna statistika?

Testna statistika je statistika na temelju koje donosimo odluku.

39. Što je kritično područje?

Kritično područje je skup vrijednosti testne statistike koje ne bismo očekivali ako je nul hipoteza istinita.

40. Što je kritična vrijednost?

Kritična vrijednost je vrijednost koja predstavlja granicu između normalnog i kritičnog područja.

41. Što je pogreška I. vrste?

Pogreška I. vrste je kad se nul hipoteza odbacuje iako je ona istinita (nalazi se u kritičnom području).

42. Što je pogreška II. vrste?

Pogreška II. vrste je kad se nul hipoteza ne odbacuje iako je alternativna hipoteza istinita.

43. Što je dvostrani test?

Dvostrani test je statistički test kod kojeg se provjerava je li parametar različit od vrijednosti zadane nul hipotezom.

44. Što je jednostrani test?

Jednostrani test je statistički test kod kojeg se provjerava je li parametar veći/manji od vrijednosti nul hipoteze.

45. Što je regresijski pravac?

Regresijski pravac je pravac koji najbolje aproksimira zavisnost između dviju slučajnih varijabli tako što minimizira zbroj kvadrata vertikalnih odstupanja.

$$S_{XX} = \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n X_i^2 - n\bar{X}_n^2, \quad S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y}_n)^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}_n^2$$

$$S_{XY} = \sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n) = \sum_{i=1}^n X_i Y_i - n\bar{X}_n \bar{Y}_n,$$

$$\hat{\beta} = \frac{S_{XY}}{S_{XX}}, \quad \hat{\alpha} = \bar{Y}_n - \hat{\beta} \bar{X}_n \quad y = \hat{\alpha} + \hat{\beta}x, \quad x \in \mathbb{R}$$