

Statistika - Projektni zadatak

Analiza faktora sreće po državama

Daniel Katić Lana Kohut
0303123347 0009069158

Rijeka, Siječanj 2026

Uvod

Ovaj projekt analizira povezanost ekonomskih i društvenih faktora sa srećom stanovništva koristeći podatke iz World Happiness Reporta (2016). Izvješće obuhvaća niz pokazatelja koji zajedno tvore tzv. indeks sreće — numerički pokazatelj koji procjenjuje koliko su stanovnici pojedine države zadovoljni svojim životom.

Cilj ove analize je istražiti koliko ekonomski pokazatelji, poput BDP-a po stanovniku, te društveni čimbenici poput obiteljske podrške, slobode izbora i povjerenja u institucije, doprinose ukupnoj percepciji sreće u različitim državama svijeta. Korištenjem osnovnih statističkih mjera (aritmetička sredina, medijan, mod, raspon, varijanca, standardna devijacija, percentili i kvartili), te analizom korelacije između ključnih varijabli, moguće je steći bolji uvid u odnose između ekonomskog blagostanja i subjektivnog osjećaja sreće.

Osim deskriptivne statistike, projekt vizualno prikazuje distribuciju vrijednosti i međusobne povezanosti podataka radi lakšeg razumijevanja rezultata. Dobiveni uvidi mogu poslužiti kao temelj za dublje analize u područjima ekonomske politike, sociologije i psihologije blagostanja.

Analiza je usmjerena prvenstveno na statističku obradu podataka i primjenu pojmova iz vjerojatnosti i statistike, dok se interpretacija rezultata razmatra na osnovnoj, ilustrativnoj razini.

Projekt je izrađen u okruženju RStudio, koristeći R Markdown i programski jezik R za obradu, analizu i vizualizaciju podataka. Autori projekta su Daniel Katić (0303123347) i Lana Kohut (0009069158).

Uvoz podataka

```
# Uvoz potrebnih biblioteka
suppressPackageStartupMessages({
  library(readr)
  library(dplyr)
})

# Podatke učitavamo u varijablu data_2016
raw_data_2016 <- read_csv("podaci/2016.csv")
spec(raw_data_2016)

## cols(
##   Country = col_character(),
##   Region = col_character(),
##   `Happiness Rank` = col_double(),
##   `Happiness Score` = col_double(),
##   `Lower Confidence Interval` = col_double(),
##   `Upper Confidence Interval` = col_double(),
##   `Economy (GDP per Capita)` = col_double(),
##   Family = col_double(),
##   `Health (Life Expectancy)` = col_double(),
##   Freedom = col_double(),
##   `Trust (Government Corruption)` = col_double(),
##   Generosity = col_double(),
##   `Dystopia Residual` = col_double()
## )

# Dodajemo stupac Godina
data_2016 <- raw_data_2016 %>% mutate(Godina = 2016)
```

Opis stupaca u datasetu *World Happiness Report 2016*

Table 1: Opis stupaca u datasetu

Naziv.stupca	Opis	Tip.podatka	Primjer
Country	Naziv države	Karakter (tekst)	Denmark
Region	Geografska regija u kojoj se država nalazi	Karakter (tekst)	Western Europe
Happiness Rank	Rang države prema indeksu sreće (1 = najsretnija država)	Numerički (integer)	1
Happiness Score	Ukupni indeks sreće za državu (0–10 skala, veća vrijednost = sretnija država)	Numerički (decimalni)	7.526
Lower Confidence Interval	Donja granica intervala pouzdanosti za Happiness Score	Numerički (decimalni)	7.460
Upper Confidence Interval	Gornja granica intervala pouzdanosti za Happiness Score	Numerički (decimalni)	7.592
Economy (GDP per Capita)	Procjena utjecaja BDP-a po stanovniku na Happiness Score (0–1 skala)	Numerički (decimalni)	1.44178
Family	Procjena utjecaja obiteljske i društvene podrške (0–1 skala)	Numerički (decimalni)	1.16374
Health (Life Expectancy)	Procjena utjecaja očekivanog životnog vijeka na sreću (0–1 skala)	Numerički (decimalni)	0.79504
Freedom	Procjena koliko su građani slobodni u donošenju životnih odluka (0–1 skala)	Numerički (decimalni)	0.57941
Trust (Government Corruption)	Povjerenje građana u vladu / razina percipirane korupcije (0–1 skala)	Numerički (decimalni)	0.44453
Generosity	Procjena razine velikodušnosti u društvu (npr. donacije, pomaganje drugima)	Numerički (decimalni)	0.36171
Dystopia Residual	Dodatna komponenta modela koja predstavlja ostatak bodova sreće (referentna vrijednost “najgorih uvjeta”)	Numerički (decimalni)	2.73939

Opisna statistika

Prikazati ćemo aritmetičku sredinu, medijan, i ostale na “Happiness Score” stupcu.

Aritmetička sredina

Aritmetička sredina je srednja vrijednost podataka, odnosno zbroj svih elemenata podijelimo sa brojem elemenata.

$$\bar{x}_n = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
arit_sred <- mean(data_2016$`Happiness Score`, na.rm = TRUE)
```

$\bar{x} = 5.3821847$

Medijan

Medijan je središnja vrijednost skupa podataka. Da bismo ga izračunali, potrebno je najprije sortirati podatke od najmanje do najveće vrijednosti.

Ako skup podataka ima neparan broj elemenata, medijan je jednostavno srednji element.

Ako skup ima paran broj elemenata, medijan se računa kao prosjek dviju srednjih vrijednosti, prema formuli:

$$\frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}$$

```
medijan <- median(data_2016$`Happiness Score`, na.rm = TRUE)
```

Medijan = 5.314

Mod

Mod je podatak koji se najčešće pojavljuje u podatkovnom skupu. On ne mora nužno postojati, jer možemo imati skup brojeva i svaki broj se pojavljuje samo jednom.

```
get_mode <- function(v) {  
  uniqv <- unique(v)  
  uniqv[which.max(tabulate(match(v, uniqv)))]  
}  
mod <- get_mode(data_2016$`Happiness Score`)
```

Mod = 6.379

Međusobna usporedba rezultata

Usporedbom aritmetičke sredine, medijana i moda može se uočiti da raspodjela indeksa sreće nije savršeno simetrična. Razlike između ovih mjera upućuju na blagu asimetriju distribucije.

Mjere raspršenja podataka

Mjere raspršenja opisuju koliko se vrijednosti slučajne varijable razlikuju od svoje središnje vrijednosti. Za razliku od mjera centralne tendencije, koje daju informaciju o tipičnoj vrijednosti, mjere raspršenja opisuju varijabilnost podataka.

U ovom projektu promatramo mjere raspršenja za neprekidne slučajne varijable, posebno za varijablu *Happiness Score*.

Varijanca i standardna devijacija

Varijanca slučajne varijable mjeri prosječno kvadratno odstupanje vrijednosti od očekivanja. Standardna devijacija je korijen varijance i izražena je u istim jedinicama kao i promatrana varijabla, zbog čega je često intuitivnija za interpretaciju.

```
varijanca <- var(data_2016$`Happiness Score`, na.rm = TRUE)
stand_dev <- sd(data_2016$`Happiness Score`, na.rm = TRUE)
```

Varijanca = 1.3034184

Standardna devijacija = 1.1416735

Dobivena varijanca pokazuje kolika je prosječna raspršenost vrijednosti indeksa sreće oko njegove srednje vrijednosti. Veća varijanca i standardna devijacija upućuju na veće razlike u razini sreće među državama, dok manja vrijednost ukazuje na homogeniju raspodjelu.

U kontekstu teorije vjerojatnosti, aritmetička sredina i varijanca u uzorku predstavljaju procjenitelje očekivanja i varijance pripadne slučajne varijable.

Vrijednost standardne devijacije pokazuje da se tipična odstupanja od srednje vrijednosti kreću oko jedne jedinice indeksa sreće, što predstavlja umjerenu razinu raspršenosti.

Empirijska vjerojatnost

U praksi se vjerojatnost često procjenjuje na temelju opaženih podataka. Takva vjerojatnost naziva se empirijska vjerojatnost i definira se kao relativna frekvencija pojavljivanja određenog događaja u uzorku.

U ovom projektu empirijsku vjerojatnost procjenjujemo koristeći podatke o indeksu sreće država.

Promatra se događaj da država ima indeks sreće veći od prosječne vrijednosti.

```
prosjeck <- mean(data_2016$`Happiness Score`, na.rm = TRUE)
emp_vjerojatnost <- mean(data_2016$`Happiness Score` > prosjeck, na.rm = TRUE)
```

Empirijska vjerojatnost = 0.4968153

Dobivena empirijska vjerojatnost predstavlja udio država u uzorku čiji je indeks sreće veći od prosječne vrijednosti. Ova vrijednost može se interpretirati kao procjena vjerojatnosti da slučajno odabrana država ima iznadprosječan indeks sreće.

Empirijska vjerojatnost dobivena na temelju uzorka predstavlja procjenitelj stvarne, ali nepoznate vjerojatnosti u populaciji.

Vrijednost empirijske vjerojatnosti bliska 0.5 posljedica je činjenice da je događaj definiran u odnosu na aritmetičku sredinu, koja približno dijeli podatke na dva dijela.

Nezavisnost i uvjetna vjerojatnost

Dva događaja su nezavisna ako ostvarenje jednog događaja ne utječe na vjerojatnost ostvarenja drugog događaja. U suprotnom, događaji su zavisni.

U kontekstu ovog projekta, promatramo povezanost između geografske regije i razine indeksa sreće.

Definiramo sljedeće događaje:

- A: država ima iznadprosječan indeks sreće
- B: država pripada odabranoj geografskoj regiji

```
regija <- "Western Europe"

ukupno_regija <- sum(data_2016$Region == regija, na.rm = TRUE)
iznadprosjeck_regija <- sum(
  data_2016$Region == regija &
  data_2016$`Happiness Score` > prosjeck,
  na.rm = TRUE
)

uvjetna_vjerojatnost <- iznadprosjeck_regija / ukupno_regija
```

Uvjetna vjerojatnost = 0.9047619

Dobivena uvjetna vjerojatnost predstavlja procjenu vjerojatnosti da država ima iznadprosječan indeks sreće uz uvjet da pripada promatranoj regiji.

Ako bi događaji A i B bili nezavisni, tada bi vrijedilo: $P(A | B) = P(A)$

Empirijska vjerojatnost = 0.4968153

Uvjetna vjerojatnost = 0.9047619

Budući da se empirijska vjerojatnost $P(A)$ razlikuje od uvjetne vjerojatnosti $P(A | B)$, može se zaključiti da promatrani događaji nisu nezavisni.

Dobiveni zaključak temelji se na empirijskoj procjeni iz uzorka te ne predstavlja strogi dokaz zavisnosti u populaciji.

Empirijska distribucijska funkcija

Distribucijska funkcija slučajne varijable opisuje vjerojatnost da slučajna varijabla poprimi vrijednost manju ili jednaku zadanoj vrijednosti.

Za neprekidne slučajne varijable, distribucijska funkcija definira se kao $F(x) = P(X \leq x)$. U praksi, kada radimo s uzorkom, distribucijska funkcija procjenjuje se pomoću empirijske distribucijske funkcije.

U ovom projektu empirijsku distribucijsku funkciju promatramo za varijablu *Happiness Score*.

```
ecdf_happiness <- ecdf(data_2016$`Happiness Score`)
```

Vrijednost distribucijske funkcije (npr. prag 6) = 0.7006369

```
plot(
  ecdf_happiness,
  main = "Empirijska distribucijska funkcija indeksa sreće",
  xlab = "Happiness Score",
  ylab = "F(x)"
)
```


Empirijska distribucijska funkcija indeksa sreće



Vrijednost empirijske distribucijske funkcije $F(6)$ predstavlja procjenu vjerojatnosti da slučajno odabrana država ima indeks sreće manji ili jednak 6.

Empirijska distribucijska funkcija daje cjelovit uvid u raspodjelu vrijednosti slučajne varijable u uzorku.

Oblik empirijske distribucijske funkcije ukazuje na postupno povećanje vrijednosti bez naglih skokova, što je u skladu s neprekidnom prirodom slučajne varijable.

Zakon velikih brojeva i centralni granični teorem

U statističkoj analizi važno je razumjeti odnos između uzorka i populacije. Zakon velikih brojeva i centralni granični teorem daju teorijsku osnovu za pouzdano zaključivanje na temelju uzorka.

Zakon velikih brojeva kaže da se aritmetička sredina uzorka približava očekivanju slučajne varijable kako se veličina uzorka povećava.

```
set.seed(123)

uzorci <- sample(
  data_2016$`Happiness Score`,
  size = 50,
  replace = TRUE
```

```
)  
  
mean(uzorci)
```

```
## [1] 5.35586
```

Centralni granični teorem kaže da distribucija aritmetičkih sredina uzoraka teži normalnoj distribuciji, neovisno o distribuciji osnovne populacije, pod uvjetom da je veličina uzorka dovoljno velika.

Ovi teoremi opravdavaju korištenje aritmetičke sredine i varijance kao procjenitelja parametara populacije te omogućuju statističko zaključivanje na temelju uzorka.

Primjena ovih teorema opravdava korištenje statističkih procjenitelja u prethodnim dijelovima analize.

Povezanost indeksa sreće i ekonomskog faktora

U ovom dijelu kratko se razmatra povezanost između indeksa sreće i jednog ekonomskog pokazatelja, konkretno BDP-a po stanovniku (*Economy (GDP per Capita)*).

Cilj ove analize nije izgradnja prediktivnog modela, već ilustracija odnosa između dviju numeričkih varijabli korištenjem korelacije.


```
korelacija <- cor(  
  data_2016$`Happiness Score`,  
  data_2016$`Economy (GDP per Capita)`,  
  use = "complete.obs"  
)
```

Korelacija = 0.790322

Dobivena vrijednost korelacijskog koeficijenta ukazuje na pozitivnu povezanost između ekonomskog blagostanja i indeksa sreće, što znači da države s višim BDP-om po stanovniku u prosjeku imaju viši indeks sreće.

```
plot(  
  data_2016$`Economy (GDP per Capita)`,  
  data_2016$`Happiness Score`,  
  xlab = "Economy (GDP per Capita)",  
  ylab = "Happiness Score",  
  main = "Povezanost BDP-a po stanovniku i indeksa sreće"  
)
```

Povezanost BDP-a po stanovniku i indeksa sreće



Na temelju grafičkog prikaza može se uočiti pozitivna povezanost između BDP-a po stanovniku i indeksa sreće. Iako odnos nije savršeno linearan, vidljivo je da države s višim ekonomskim blagostanjem u prosjeku imaju više vrijednosti indeksa sreće.

Važno je naglasiti da korelacija ne implicira uzročnost, već isključivo statističku povezanost između promatranih varijabli.

Testiranje statističke hipoteze za sredinu

Uz deskriptivnu analizu, moguće je provesti i statističko zaključivanje o populaciji. U ovom dijelu provodi se jednostrani t-test za aritmetičku sredinu indeksa sreće.

Cilj je ispitati je li prosječni indeks sreće država statistički veći od 5.

T-test za jednu sredinu

T-test je statistički postupak kojim se ispituje razlikuje li se aritmetička sredina uzorka statistički značajno od zadane vrijednosti populacijske sredine. Koristi se kada populacijska varijanca nije poznata, što je u praksi najčešći slučaj.

U ovom radu provodi se jednostrani t-test kojim se ispituje je li prosječni indeks sreće država veći od vrijednosti 5.

Postavljamo hipoteze:

$H_0: \mu = 5$ (prosječni indeks sreće jednak je 5)

$H_1: \mu > 5$ (prosječni indeks sreće veći je od 5)

```
t_test_rez <- t.test(  
  data_2016$`Happiness Score`,  
  mu = 5,  
  alternative = "greater"  
)
```

```
t_test_rez
```

```
##  
## One Sample t-test  
##  
## data:  data_2016$`Happiness Score`  
## t = 4.1945, df = 156, p-value = 2.286e-05  
## alternative hypothesis: true mean is greater than 5  
## 95 percent confidence interval:  
##  5.231418      Inf  
## sample estimates:  
## mean of x  
##  5.382185
```

Rezultat testa daje p-vrijednost koja predstavlja vjerojatnost dobivanja opaženog uzorka pod pretpostavkom da je nul-hipoteza istinita.

Ako je p-vrijednost manja od 0.05, odbacujemo nul-hipotezu i zaključujemo da je prosječni indeks sreće statistički značajno veći od 5.

Na taj način, osim opisne statistike, koristimo i metode statističkog zaključivanja o populaciji.

Budući da je dobivena p-vrijednost znatno manja od 0.05 ($p < 0.001$), odbacujemo nul-hipotezu te zaključujemo da je prosječni indeks sreće statistički značajno veći od 5.

Zaključak

U ovom projektu provedena je deskriptivna i inferencijska statistička analiza indeksa sreće država koristeći podatke iz World Happiness Reporta (2016). Korištenjem mjera centralne tendencije, mjera raspršenja te pojmova iz vjerojatnosti i statistike prikazano je kako se osnovni statistički koncepti mogu primijeniti na stvarne podatke.

Analiza je pokazala umjerenu do visoku varijabilnost indeksa sreće među državama, kao i pozitivnu povezanost između ekonomskog blagostanja i razine sreće. Empirijske procjene vjerojatnosti, distribucijske funkcije te testiranje statističkih hipoteza omogućile su i statističko zaključivanje o populaciji.

Dobiveni rezultati temelje se na uzorku podataka te služe kao ilustracija statističkih metoda, a ne kao konačni zaključci o populaciji. Projekt potvrđuje važnost statističkog pristupa u analizi složenih društvenih pojava.